

# Técnicas de Seleção de Subconjunto

Grupo 6

Matheus Araujo  
Gabriel Teixeira  
Marcelo Mota

# Definição

O processo é mais custoso que a ordenação dos atributos.

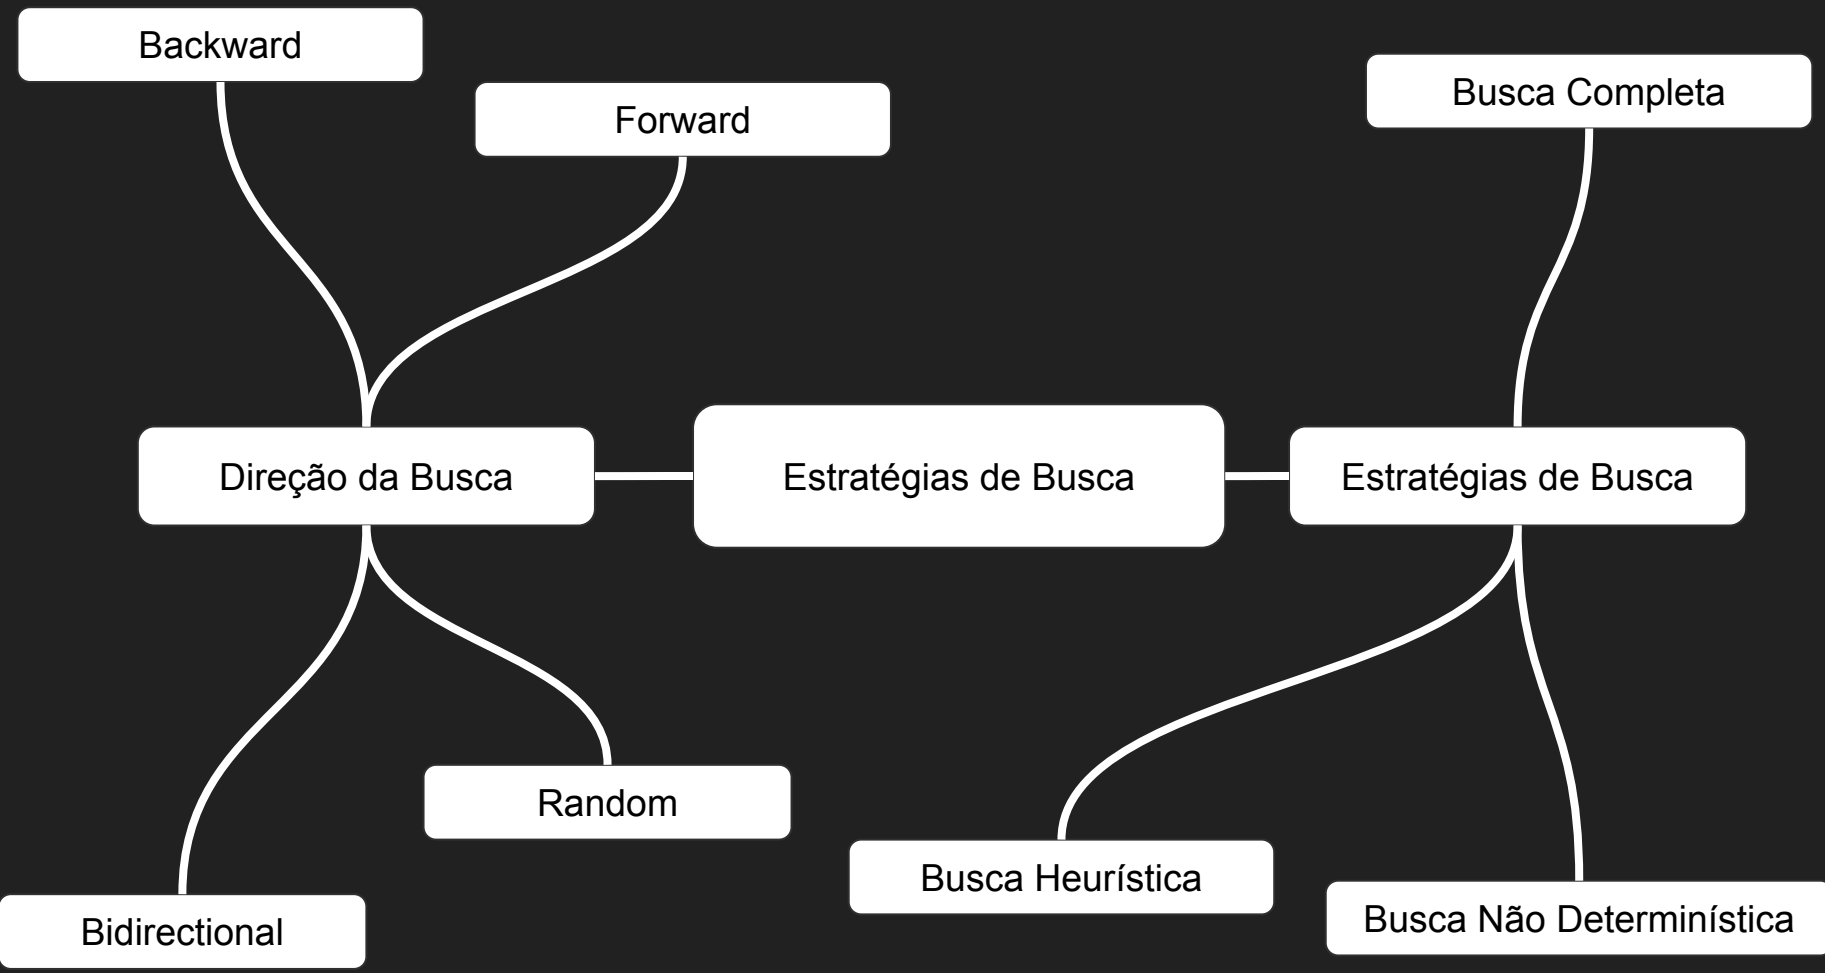
Tornam-se intratáveis quando o número de atributos é muito grande.

# Objetivo

Obter um conjunto de atributos que melhore o desempenho do modelo.

# Passos fundamentais (Blum & Langley, 1997)

- 1° - Definir os pontos de partida e a direção da busca;
- 2° - Escolher a estratégia de busca;
- 3° - Selecionar critérios de avaliação;
- 4° - Determinar o critério de parada.



# Critérios de Parada

Encerrar a busca quando:

- Opção 1 - Todos os subconjuntos forem testados (EXAUSTIVA);
- Opção 2 - Um critério de desempenho for atingido.

# Algumas considerações

As técnicas de seleção de subconjunto podem ser aplicada em tarefas supervisionadas e não supervisionada.

A qualidade do agrupamento de dados impacta os resultados.

# Exemplo

Implementar uma estratégia de busca por geração aleatória usando uma técnica de Seleção de Subconjunto, onde geramos aleatoriamente um subconjunto de possíveis soluções e avaliamos qual delas é a melhor.



Vamos definir uma função que avalia uma solução (neste caso, a soma dos quadrados dos elementos de um vetor).

```
# Função objetivo: soma dos quadrados dos elementos  
def objetivo(solucao):  
    return sum(x**2 for x in solucao)
```

Vamos gerar aleatoriamente soluções possíveis (subconjuntos).

```
# Função para gerar uma solução aleatória (subconjunto de números entre -10 e 10)  
def gerar_solucao(tamanho=5, limite=-10, max_value=10):  
    return [random.randint(limite, max_value) for _ in range(tamanho)]
```

Para cada solução gerada, avaliamos a qualidade usando a função objetivo.

```
# Parâmetros da busca  
num_solucoes = 100 # Número de soluções geradas  
tamanho_subconjunto = 5 # Tamanho do subconjunto (tamanho do vetor)  
melhor_solucao = None  
melhor_valor = float("inf") # Inicializando com um valor muito alto
```

Escolhemos a melhor solução gerada.

```
# Estratégia de busca por geração aleatória
for _ in range(num_solucoes):
    solucao_aleatoria = gerar_solucao(tamanho_subconjunto)
    valor = objetivo(solucao_aleatoria)

    if valor < melhor_valor: # Se encontramos uma solução melhor, atualizamos
        melhor_valor = valor
        melhor_solucao = solucao_aleatoria
```

# Resultado

```
# Resultado final
print("Melhor solução encontrada:", melhor_solucao)
print("Valor da função objetivo:", melhor_valor)
```

```
PS C:\Users\mathe\Desktop\Aprendizagem de Máquina> python -u "c:\Users\mathe\Desktop\Aprendizagem de Máquina\unidade_01\busca_aleatoria.py"
Melhor solução encontrada: [1, 0, -1, -1, -5]
Valor da função objetivo: 28
PS C:\Users\mathe\Desktop\Aprendizagem de Máquina> python -u "c:\Users\mathe\Desktop\Aprendizagem de Máquina\unidade_01\busca_aleatoria.py"
Melhor solução encontrada: [-3, 2, 1, -1, 1]
Valor da função objetivo: 16
PS C:\Users\mathe\Desktop\Aprendizagem de Máquina> python -u "c:\Users\mathe\Desktop\Aprendizagem de Máquina\unidade_01\busca_aleatoria.py"
Melhor solução encontrada: [-2, 0, -1, 3, 1]
Valor da função objetivo: 15
PS C:\Users\mathe\Desktop\Aprendizagem de Máquina>
```

# Referências

FACELI, Katti et al. Inteligência artificial: uma abordagem de aprendizado de máquina. . Rio de Janeiro: LTC. . Acesso em: 13 nov. 2023. , 2011

Aurélien Géron. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. "O'Reilly Media, Inc.", 2019.